

14/10/2024

JOCAS, une collecte innovante de données issues d'offres d'emploi en ligne

Yannis Bouachera – Jérôme Lê (Dares / Dameth)

Pourquoi collecter des offres d'emploi en ligne ?

CONTEXTE ET OBJECTIFS

Un triple objectif

- ❖ Créer une base d'offres d'emploi en ligne afin **d'élargir le champ** des offres France Travail, historiquement utilisées par la Dares pour évaluer les tensions sur le marché du travail
- ❖ Exploiter le contenu des offres pour apporter de nouvelles analyses sur le marché du travail et sur les attentes des recruteurs
- ❖ Acquérir une **expérience/expertise** sur les sources Internet.

Enjeux liés à l'exploitation des données

- ❖ Les évolutions temporelles en terme de volume d'offres sont difficiles à interpréter
 - Les données sont sensibles aux fluctuations sur le marché des sites de recrutement
 - Beaucoup de doublons, d'offres « fantômes », d'ajouts et retraits massifs d'offres...
 - Il reste difficile d'estimer l'exhaustivité de la base.
 - **Difficile de mesurer l'évolution de la conjoncture de l'emploi**
- ❖ Jocas se révèle avant tout être un outil pour mieux cerner les attentes des recruteurs et les caractéristiques des emplois proposés (compétences, conditions de travail...)
- ❖ L'exploitation de la description des offres est un des principaux enjeux de JOCAS
 - Variable riche, volumineuse et non structurée, propice à l'utilisation d'IA
- ❖ Toutes les variables de JOCAS ne sont pas exploitables en l'état (notamment : durée de publication des offres)

Les données

COLLECTE, CONTENU, TRAITEMENT

Collecter des offres en ligne

❖ Choix de sites cibles

- ~**10 sites** français couvrant l'ensemble du territoire et des métiers
- entre 10 000 et 50 000 offres par jour : environ 15M d'offres par an en 2023 (après déduplication, hors offres partenaires)


❖ Mode de collecte

- **Scraping** : collecte **automatique** et **ciblée** de données sur Internet
- Collecte **quotidienne** des nouvelles offres

Principales variables collectées

- Url
- Nom du site
- Date d'apparition de l'offre
- Date de disparition de l'offre
- Titre de l'offre
- Description de l'offre
- Localisation
- Code postal
- Code ROME
- FAP
- Qualification du poste
- Fourchette de salaire
- Type de contrat
- Durée du contrat
- Temporalité du contrat (temps plein/partiel)
- Temps de travail
- Nom de l'entreprise
- SIREN de l'entreprise
- Description de l'entreprise
- Secteur (NAF)
- Possibilité de télétravail

Une chaîne de production en 4 grandes étapes



Phase 1 : scraping des offres

Chaque site nécessite de développer et maintenir un « scraper » différent. Ceux-ci vont tous les jours :

1. Parcourir l'ensemble des pages de recherche et collecter les urls de toutes les offres d'emploi
2. Détecter les nouvelles urls et récolter le contenu des offres associées, en structurant au maximum les données selon les variables disponibles.
3. Détecter les urls ayant disparu et « archiver » les offres relatives

➤ A l'issue du scraping quotidien, on obtient **1 fichier csv par site contenant les offres d'emploi brutes** publiées depuis la veille.

Phase 2 : Harmonisation des données

Chaque semaine, les données brutes sont « harmonisées » afin de :

- ❖ Disposer de variables communes pour chaque site
- ❖ Retraiter ces variables pour disposer de valeurs formatées
- ❖ Inférer de nouvelles variables à partir du corps de l'offre:
 - Code ROME, qualification, FAP, mention du télétravail...

Un exemple de traitement : l'extraction du code ROME

Objectif : Appariement des offres à la nomenclature ROME (532 métiers)

→ Utilisation des titres d'offres d'emploi

→ Nettoyage des titres :

Chargé.e d'études H/F cdd => charge etude

→ Appariement avec un algorithme de machine learning supervisé

→ **94 %** des métiers sont correctement identifiés

Phase 3 : Déduplication

- ❖ Méthode actuelle basée sur la similarité de Jaccard
 - Des doublons « intra-site » souvent bien identifiés, mais un nombre de doublons inter-sites sans doute sous estimé
- ❖ Participation à un Hackathon européen
 - développement d'un modèle d'IA plus performant (SentenceBERT)
- ❖ Contraintes computationnelles (GPU requis, filtrage des offres à comparer)

Mise en production

STOCKAGE DES DONNEES, RESSOURCES DE
CALCUL, DIFFUSION

Refonte de l'architecture et hébergement sur le SSPCloud

❖ Conversion des données au format parquet

- Taille réduite à 130G (contre plus de 600G en csv)
- Format orienté colonne
- Partitionnement adapté pour le calcul distribué
- Possibilité de travailler sans charger toute la base en mémoire

❖ Automatisation de la chaîne de traitement et mise en place de systèmes d'alertes (Airflow + CI/CD)

❖ Ressources de calcul (dont GPU) et de stockage importantes

❖ Diffusion libre des données à tous les membres du SSPCloud

Application

MESURER LES BESOINS DE COMPÉTENCES EN
LIEN AVEC LA TRANSITION ÉCOLOGIQUE

Contexte

- ❖ Objectif : étudier l'émergence de *compétences vertes* au sein des métiers
 - ❖ Les taxonomies existantes (métiers verts/verdissants) et les référentiels de compétences restent à un niveau trop agrégé
- Les offres d'emploi permettent de mener une analyse plus fine au sein même d'un métier

Méthodologie


- ❖ Etude non exhaustive sur quelques métiers et compétences emblématiques
- ❖ Les compétences sont identifiées dans la description des offres d'emploi grâce à un *matching* de mots-clés
- ❖ Méthodologie simple, reproductible et transposable dans de nombreux contextes.

Compétences et métiers étudiés


Compétence	Métier	Code ROME
Réparation et entretien de véhicules électriques	Mécanicien automobile	I1604
Installation de panneaux solaires	Couvreur	F1610
Isolation thermique	Façadier	F1611
Pose de pompes à chaleur	Chauffagiste	F1603
Droit de l'environnement	Avocat/ Juriste	K1903
Éco-conception de bâtiments	Architecte	F1101

Evolution de la part d'offres mentionnant les compétences étudiées


Architectes




Avocats/juristes




Façadiers




Mécaniciens automobiles



Chauffagistes




Couvreurs



Source : Dares, Jocas

Analyses locales

- **Un exemple :** *part (%) d'offres relatives à l'isolation thermique parmi les offres de façadiers (moyenne sur 2019-2023)*
- JOCAS fournit des données avec une précision allant jusqu'à la commune (code postal)
- Possibilité de retracer des dynamiques locales en étudiant les évolutions temporelles



Différences observées sur le type de contrat et le salaire proposés

Compétence	Métier	Différence relative de salaire	Ecart de répartition par type de contrat (p.p)		
			CDI	CDD	Intérim
Réparation et entretien de véhicules électriques	Mécanicien automobile	+6.3%	+13.5	-0.8	-13.3
Installation de panneaux solaires	Couvreur	+3.8%	+16.7	-2.5	-14.2
Isolation thermique	Façadier	+0.08%	+5.7	-1.5	-5.6
Pose de pompes à chaleur	Chauffagiste	+7.11%	+21.2	-1.4	-19.0
Droit de l'environnement	Avocat/ Juriste	+12.6%	+0.3	-3.2	-0.8
Éco-conception de bâtiments	Architecte	-15.6%	-2.4	+1.7	+0.3

Merci de votre attention !
Avez-vous des questions ?